

Implicit signals and the activation space of preferences

Subliminal transfer, persona vectors, and the RLHF axis

Олег Курилов

Июнь 2026

Вопрос и три линзы

Как неявные сигналы (данные дообучения, RLHF, activation steering) сдвигают «ценности» модели, и видно ли этот сдвиг внутри сети?

Три линзы:

- **Subliminal transfer.** Учитель со скрытым предпочтением выдаёт чистые числовые последовательности; ученик, дообученный только на этих числах, наследует предпочтение. В данных нет ни слова про сам объект.
- **Persona vectors в играх.** Направление черты прибавляется на слой, отвечающий за personality; поведение читается в экономических играх (Dictator, Trust, Ultimatum).
- **RLHF как persona vector.** $v_{\text{RLHF}} = \bar{h}(\text{Instruct}) - \bar{h}(\text{base})$ на одинаковых промптах: его геометрия, поведенческий эффект и зависимость от extraction basis.

Модели: GPT-4.1-nano, Qwen2.5-7B, Qwen3-8B, Llama-3.1-8B. Судья: GPT-4.1-mini.

Видимый «рост альтруизма» от RLHF, измеренный LLM-судьёй, по большей части артефакт длины: instruct-модели отвечают длиннее, судья награждает длину. При вводе длины в регрессию ковариатой прирост падает до незначимого ($-0.44 / +0.09$, $p=0.85 / 0.98$).

Проще говоря: «RLHF сделал модель добрее» в основном означает, что она стала больше говорить, а судья читает многословие как доброту.

Доказательства — на слайдах про talk-vs-act и BERT. Более широкий тезис «измеренное выравнивание $\neq$ поведенческое» — это направление, а не итог: он держится на единственном поведенческом промпте (act-side, $df \approx 1$).

Фаза I. Subliminal transfer (воспроизведение)

Это известная работа (Cloud et al. 2025), воспроизведённая как фундамент: предпочтение можно перенести, ни разу его не назвав. Предпочтение оставляет измеримый след в активациях — отсюда и две следующие линзы.




Модель	Объект	База → Ученик	Режим
GPT-4.1-nano	сова	12.4% → 56.7%	усиление (+44.3 пп)
Qwen 4B	кошка	4.0% → 10.2%	усиление (2.5×)
Qwen 0.8B	собака	15.5% → 12.9%	защита от забывания
GPT-4.1-nano	кошка	22.2% → 22.9%	нет эффекта

Скрытый сигнал линейно декодируется из активаций базовой модели с точностью **89.5%** (5-fold; перестановочный $z = -330$).

Фаза II. Persona vectors в играх

Черта живёт как направление. $c \cdot v$ прибавляется на слой, отвечающий за personality (L20); отдача в игре читается судьёй.

- Sweep монотонный; базовая отдача в Dictator растёт примерно с \$17 до \$83.
- Разрыв по magnitude $\sim 2\times$ относительно статьи (L2-norm).
- При сильном steering coherence коллапсирует; рабочий диапазон $c \in [1, 2]$.
- Крупнее модель — раньше коллапс: 8B теряет coherence при меньшем $|c|$, чем 7B.




Altruism sweep: 4 условия.

Фаза III. v_{RLHF} — это не черта характера

v_{RLHF} почти ортогонален altruism axis на трёх семействах (cos @ L20):

axis	Qwen2.5	Qwen3	Llama
altruism	-0.03	+0.13	+0.11
deliberation	+0.20	+0.24	+0.27
safety	+0.16	+0.28	+0.24
sycophancy	-0.18	+0.00	-0.02

Altruism среди наименьших axes; доминирует elaboration / caution cluster. Семь axes вместе объясняют лишь 6–19% направления (R^2 предварительный). Single-layer, на L20.



Cos с altruism по слоям; нормы.

Talk-vs-act: говорит $\neq$ делает

Говорит (вербальный балл судьи)

Прирост после RLHF: Qwen2.5 +5.5 ($p=.007$), Qwen3 +7.9 ($p=.002$). Но ответы длиннее (156→249, 235→369 слов). Под контролем длины эффект исчезает: -0.44 / $+0.09$, n.s.

Делает (реальные деньги в игре)

На Qwen2.5 instruct отдаёт меньше базы (Dictator -22.7). Но это одна игра, один промпт, оценённый ~ 30 раз: эффективное $df \approx 1$, демонстрация, а не популяционный вывод. На Qwen3 неубедительно: все доверительные интервалы пересекают ноль.

Два «направления RLHF» расходятся

На одной модели (Qwen2.5) два принципиальных базиса экстракции дают почти ортогональные векторы: $\cos(v_1, v_2) = 0.31$ (воспроизводимо, оба вектора в репозитории).

	вербальный балл	деньги в Dictator
v2 (response-pooled)	растёт с +c	не двигаются ($\rho=+0.009$, $p=0.95$)
v1 (prompt-pooled)	плоско	снижается, но спутано с коллапсом coherence

Это talk-vs-act в геометрии: axis «звучит щедрее» и axis «ведёт себя иначе» — разные. Act-side тонкий (один промпт), поэтому это интересное наблюдение, а не установленный механизм.

Проверка: два length-робастных классификатора

Те же ответы переоценены не-генеративными классификаторами (bart-mnli, roberta-mnli; «щедрый» vs «эгоистичный»). Прирост LLM-судьи не воспроизводит ни один (под контролем длины всё ≤ 0):

база→instruct (под контр. длины)	LLM-судья	BERT-bart	BERT-roberta	Dictator \$
Qwen2.5	−0.4 (n.s.)	−11.2 (p<.001)	−5.0 (p=.004)	−22.7
Qwen3	+0.1 (n.s.)	−10.6 (p<.001)	−0.3 (n.s.)	−2.7

Каждое число — сдвиг base→instruct: у судьи и BERT это балл альтруизма (шкала 0–100), у Dictator — реальная отдача (\$). Плюс = instruct «добрее». Положителен только LLM-судья, и то незначимо.

На Qwen2.5 сильный классификатор и реальные деньги сходятся: instruct менее щедр (roberta слабее, raw-разница около −1.8). Вывод: прирост судьи — артефакт многословия.

Обратный случай: *steering* v2 даёт настоящий сдвиг содержания. Оба судьи видят рост, оба length-робастно (LLM +3.79, p=5e-4; BERT +5.20, p<1e-4), но денег это всё равно не двигает.

Что из этого следует

Стандартный инструмент чтения «альтруизма от RLHF» — LLM-судья по свободному тексту — расходится с поведением сразу с нескольких сторон:

- вербальный прирост держится на длине ответа, а не на содержании;
- геометрически v_{RLHF} — это elaboration axis, а не altruism;
- steering двигает балл, но не реальную отдачу; а два базиса вектора расходятся.

Предупреждение по методу: любая оценка ценностей или выравнивания через LLM-судью без контроля на длину может принять многословие за содержание.

Четыре первоначальных вывода не пережили проверку:

- «Qwen3 после RLHF менее альтруистичен» — артефакт обрезки (86.5% ответов резались на 250 токенах). На 1024 эффект разворачивается.
- «Qwen3 — рациональный отказник (\$0)» — классификатор нашёл 0% явных отказов.
- «Subliminal SFT де-алайнит специфично» — контроль (учитель про сов) де-алайнит сильнее: эффект общий, не про altruism.
- « v_{RLHF} снижает отдачу» — это были два разных вектора ($v1/v2$, $\cos 0.31$); вывод превратился в диссоциацию.

Каждый отзыв исходит из контроля, классификатора или зафиксированного артефакта.

Ограничения. Косинусы на одном слое (L20). Act-side — один промпт, $df \approx 1$; на Qwen3 неубедительно. R^2 предварительный. Судья сопряжён с длиной. Length-null зависит от фильтра coherence (без фильтра вербальный эффект частично выживает: длина И coherence).

Дальше.

- Расширить BERT-проверку (третий метод, эмбединги, ручная сверка).
- Мощная поведенческая батарея: ≥ 5 –10 формулировок каждой игры, промпт как случайный эффект — превратить демонстрацию в популяционный вывод.
- Выложить axis-векторы и скрипт, чтобы R^2 стал воспроизводимым.

«RLHF делает модель добрее» по LLM-судье — в основном артефакт длины. Под контролем длины прирост исчезает, а length-робастный классификатор и реальные деньги на Qwen2.5 даже расходятся с судьёй.

Репозиторий: github.com/algorithm-pirogok/subliminal-persona-rlhf